Projeto final da Disciplina de Análise de Dados

Os projetos deverão ser desenvolvidos em grupos de 4 alunos, em que cada um deverá apresentar uma parte do projeto.

Cada projeto deverá ter seu código fonte desenvolvido em notebook, postado no moodle.

Cada projeto deverá ter um artigo escrito sobre o projeto com um problema de negócio a resolver e detalhar as características do dataset a ser analisado. Deverá detalhar as técnicas utilizadas para desenvolver o projeto.

Ao final deverá descrever a resolução do projeto e sua conclusão final.

Postagens:

Dia 14/11/2026: Código Fonte do Projeto. O notebook do projeto deverá ter o nome de Grupo_N.ipynb, onde, N é o número do grupo. O arquivo compactado deverá ter o mesmo nome. Apenas um representante do grupo deverá postar o arquivo.

Dia 28/11/2026: Artigo em PDF desenvolvido pelo Grupo. O arquivo deverá o nome de Grupo_N.pdf, onde N, é o número do grupo que deverá ser postado apenas pelo representante do grupo.

Estrutura do Projeto:

Os projetos devem conter as seguintes fases:

- Estabelecimento do problema de negócio

- Carga do dataset do arquivo de dados

- Definição da coluna alvo (tarjet) de estudos

- Análise exploratória de dados como dados ausentes, dados outliers, verificação de duplicidade de colunas, verificação de dados com colunas redundantes.

- Preparação de dados de entrada e dados de saída.

- Preparar a aleatoriedade de dados.

- Divisão de dados em treino/validação/teste (70/15/15)

- Balanceamento de dados.

- Conversão dos dados para matrizes numpy.

- Normalização dos dados.

- Construção de cálculo das métricas, especificidade, roc auc score, accuracy score, precision score e reacall score.

- Construção de três modelos para treinamento dos dados e definir o melhor deles.
    - Regressão Linear
    - Naive Bayes
    - Random Forest
- Avaliação dos três modelos utilizando métricas.
- Cálculo da Previsão dos três modelos utilizando os métodos predict e predict_proba.
- Avaliação e testes para novos dados.

Cada um dos 10 temas abaixo possui um contexto de negócio bem definido e utiliza repositórios públicos confiáveis (Kaggle e UCI Machine Learning).

1. **Detecção de Fraudes em Transações Financeiras (Grupo 1)**

Grupo 1

Paulo
Gabriel Dias
Lucas Moscofian
Matheus Lopes

- **Problema de Negócio:** Identificar se uma transação bancária ou de cartão é fraudulenta para bloquear pagamentos e evitar perdas financeiras.
- **Coluna Alvo (target):** is_fraud ou Class (0 = Legítima, 1 = Fraude).
- **Dataset:** Credit Card Fraud Detection (Kaggle)

2. **Previsão de Churn de Clientes em Telecomunicações (Grupo 2)**

Grupo 2

Ana Julia
Isabelly Nathália
Anderson da Silva

- **Problema de Negócio:** Identificar clientes com alta probabilidade de cancelar a assinatura para aplicar campanhas de retenção.
- **Coluna Alvo (target):** Churn (0 = Não, 1 = Sim).
- **Dataset:** Telco Customer Churn (Kaggle)

3. **Diagnóstico de Doenças Cardíacas**

Grupo 3
Renan
Valença
Maycon C.
Gustavo
Tenório
Luiz

- **Problema de Negócio:** Auxiliar médicos na triagem inicial de pacientes para identificar quem possui alto risco de doença arterial coronariana.
- **Coluna Alvo (target):** target ou num (0 = Saudável, 1 = Com doença cardíaca).
- **Dataset: Link principal (Kaggle):** Kaggle - Heart Disease Dataset (johnsmith88)

4. **Análise de Risco de Crédito Imobiliário**

Grupo 4
Giovanni
Medici
Gaspar Silva
David Martins
Ryan Furtado

- **Problema de Negócio:** Determinar se um solicitante de empréstimo honrará os pagamentos ou entrará em inadimplência (*default*).
- **Coluna Alvo (target):** Loan_Status (Y = Aprovado, N = Recusado) ou BAD (0 = Pagou, 1 = Inadimplente).
- **Dataset:** Loan Prediction Dataset (Kaggle)

5. **Detecção de Câncer de Mama (Breast Cancer Wisconsin)**

Grupo 5
Camila
Pereira
Giovanna
Brandão
Artur
Miranda

- **Problema de Negócio:** Auxiliar radiologistas na classificação de tumores mamários extraídos por punção de agulha fina (FNAC) para determinar se a massa celular é **benigna** ou **maligna**, acelerando o tempo de resposta em diagnósticos médicos.
- **Coluna Alvo (target):** diagnosis (0 = Benigno / B, 1 = Maligno / M).
- **Links para Download:**
    - Kaggle - Breast Cancer Wisconsin (Diagnostic)
    - UCI Machine Learning Repository - Breast Cancer Wisconsin

6. Detecção de Adimplência em Telemarketing Bancário (Bank Marketing)

Grupo 6

Guilherme

Kayky

Lorena

Nicoly

- **Problema de Negócio:** Uma instituição bancária deseja prever quais clientes aceitarão contratar um depósito a prazo fixo (term deposit) após campanhas de telemarketing. O objetivo é otimizar o foco da equipe de vendas e reduzir custos de ligações desnecessárias.
- **Coluna Alvo (target):** y (0 = no / Não contratou, 1 = yes / Contratou).
- **Tamanho do Dataset:** ~1 MB em arquivo ZIP.
- **Repositório:** UCI Machine Learning Repository.
- **Link Direto do Repositório (Download Completo):**
  - UCI Repository - Bank Marketing Dataset *(basta clicar no botão "Download" na página)*.
  - Link Direto do Zip na UCI

7. Rotatividade de Funcionários (HR Analytics)

Grupo 7

Rafael Yukio

Kaian Muniz

Gabriel Trolezi

João Vitor Souza

- **Problema de Negócio:** Entender os fatores que levam funcionários a pedirem demissão e prever quais colaboradores estão em risco de saída.
- **Coluna Alvo (target):** Attrition (0 = Permanece, 1 = Saiu da empresa).
- **Dataset:** IBM HR Analytics Employee Attrition (Kaggle)

8. Detecção de Inadimplência em Cartões de Crédito (Taiwan Dataset)

Grupo 8

Maria Eduarda M

Ramona P

Vitor Januario

Jonas R.

- **Problema de Negócio:** Prever se um cliente deixará de pagar a fatura do cartão no próximo mês com base em históricos de pagamento e saldos.
- **Coluna Alvo (target):** default.payment.next.month (0 = Adimplente, 1 = Inadimplente).
- **Dataset:** Default of Credit Card Clients (UCI / Kaggle)

9. Classificação de Satisfação de Clientes Bancários (Bank Customer Churn)

Grupo 9

Reinaldo Henrique

Pedro Guedes

João Yoneyama

Felipe Paez

- **Problema de Negócio:** Identificar a probabilidade de um cliente encerrar sua conta corrente em um banco comercial com base no saldo, score de crédito, idade e número de produtos contratados.
- **Coluna Alvo (target):** Exited (0 = Permaneceu, 1 = Cancelou a conta).
- **Tamanho do Dataset:** ~300 KB (10.000 linhas).
- **Repositório:** Kaggle / Hugging Face.
- **Links para Download:**
  - Kaggle - Bank Customer Churn Dataset
  - Link Direto Alternativo (GitHub / CSV Direto sem login)

10. Previsão de Cancelamento de Reservas de Hotel

Grupo 10

Gabriel Ramaglia

Ian Souza

Victor vilas Boas

Pedro Hardmann

- **Problema de Negócio:** Identificar reservas com alto risco de cancelamento prévio para otimizar o *overbooking* e a receita do hotel.
- **Coluna Alvo (target):** is_canceled (0 = Confirmada, 1 = Cancelada).
- **Dataset:** Hotel Booking Demand (Kaggle)